



VYSOKÉ UČENÍ TECHNICKÉ V BRNĚ

BRNO UNIVERSITY OF TECHNOLOGY

FAKULTA ELEKTROTECHNIKY A KOMUNIKAČNÍCH TECHNOLOGIÍ

FACULTY OF ELECTRICAL ENGINEERING AND COMMUNICATION

ÚSTAV AUTOMATIZACE A MĚŘICÍ TECHNIKY

DEPARTMENT OF CONTROL AND INSTRUMENTATION

LOKALIZACE ZDROJŮ AKUSTICKÉ EMISE

ACOUSTIC EMISSION SOURCE LOCALIZATION

SEMESTRÁLNÍ PRÁCE

SEMESTRAL THESIS

AUTOR PRÁCE

AUTHOR

Jan Tomšej

VEDOUCÍ PRÁCE

SUPERVISOR

doc. Ing. Petr Beneš, Ph.D.

BRNO 2025



Semestrální práce

bakalářský studijní program **Automatizační a měřicí technika**

Ústav automatizace a měřicí techniky

Student: Jan Tomšej

ID: 256421

Ročník: 3

Akademický rok: 2025/26

NÁZEV TÉMATU:

Lokalizace zdrojů akustické emise

POKYNY PRO VYPRACOVÁNÍ:

Akustické emise (AE) je jedna z metod nedestruktivního testování. Své využití nachází například při testování tlakových nádob. Cílem práce je ověřit možnosti využití metod strojového učení pro lokalizaci zdrojů AE.

Zadání práce lze rozdělit do následujících bodů:

- 1) Vypracujte přehled současného stavu metod lokalizace zdrojů AE
- 2) Vybrané algoritmy založené na čase příchodu implementujte, např. v prostředí Matlab, Python nebo LabVIEW
- 3) Na geometricky vhodném zkušebním vzorku naměřte sadu dat využitelných pro další zpracování pomocí implementovaných algoritmů
- 4) Navrhněte a realizujte metody strojového učení pro zpřesnění detekce času příchodu a zvýšení odolnosti v zašuměném prostředí.
- 5) Diskutujte možnosti lokalizace pro heterogenní nebo anizotropní prostředí.

Na semestrální práci je nutné vypracovat alespoň první tři body zadání.

DOPORUČENÁ LITERATURA:

ČSN EN 14584 Nedestruktivní zkoušení - Akustická emise - Zkoušení kovových tlakových zařízení během přijímací zkoušky -planární lokalizace zdrojů akustické emise.

Termín zadání: 15.9.2025

Termín odevzdání: 6.1.2026

Vedoucí práce: doc. Ing. Petr Beneš, Ph.D.

Ing. Miroslav Jirgl, Ph.D.

předseda rady studijního programu

UPOZORNĚNÍ:

Autor semestrální práce nesmí při vytváření semestrální práce porušit autorská práva třetích osob, zejména nesmí zasahovat nedovoleným způsobem do cizích autorských práv osobnostních a musí si být plně vědom následků porušení ustanovení § 11 a následujících autorského zákona č. 121/2000 Sb., včetně možných trestněprávních důsledků vyplývajících z ustanovení části druhé, hlavy VI. díl 4 Trestního zákoníku č.40/2009 Sb.

ABSTRAKT

Abstrakt práce v originálním jazyce

KLÍČOVÁ SLOVA

akustická emise, zdroje akustické emise, umělá neuronová síť

ABSTRACT

Překlad abstraktu (v angličtině, pokud je originálním jazykem čeština či slovenština; v češtině či slovenštině, pokud je originálním jazykem angličtina)

KEYWORDS

acoustic emission, acoustic emission sources, artificial neural network, artificial neural network localization (v angličtině, pokud je originálním jazykem čeština či slovenština; v češtině či slovenštině, pokud je originálním jazykem angličtina)

ROZŠÍŘENÝ ABSTRAKT

Výtah ze směrnice rektora 72/2017:

Bakalářská a diplomová práce předložená v angličtině musí obsahovat rozšířený abstrakt v češtině nebo slovenštině (čl. 15). To se netýká studentů, kteří studují studijní program akreditovaný v angličtině. (čl. 3, par. 7)

Nebude-li vnitřní normou stanoveno jinak, doporučuje se rozšířený abstrakt o rozsahu přibližně 3 normostrany, který bude obsahovat úvod, popis řešení a shrnutí a zhodnocení výsledků. (čl. 15, par. 5)

TOMŠEJ, Jan. *Lokalizace zdrojů akustické emise*. Semestrální práce. Brno: Vysoké učení technické v Brně, Fakulta elektrotechniky a komunikačních technologií, Ústav automatizace a měřicí techniky, 2025. Vedoucí práce: doc. Ing. Petr Beneš, PhD.

Prohlášení autora o původnosti díla

Jméno a příjmení autora: Jan Tomšej
VUT ID autora: 256421
Typ práce: Semestrální práce
Akademický rok: 2025/26
Téma závěrečné práce: Lokalizace zdrojů akustické emise

Prohlašuji, že svou závěrečnou práci jsem vypracoval samostatně pod vedením vedoucí/ho závěrečné práce a s použitím odborné literatury a dalších informačních zdrojů, které jsou všechny citovány v práci a uvedeny v seznamu literatury na konci práce.

Jako autor uvedené závěrečné práce dále prohlašuji, že v souvislosti s vytvořením této závěrečné práce jsem neporušil autorská práva třetích osob, zejména jsem nezasáhl nedovoleným způsobem do cizích autorských práv osobnostních a/nebo majetkových a jsem si plně vědom následků porušení ustanovení § 11 a následujících autorského zákona č. 121/2000 Sb., o právu autorském, o právech souvisejících s právem autorským a o změně některých zákonů (autorský zákon), ve znění pozdějších předpisů, včetně možných trestněprávních důsledků vyplývajících z ustanovení části druhé, hlavy VI. díl 4 Trestního zákoníku č. 40/2009 Sb.

Brno
.....
podpis autora*

* Autor podepisuje pouze v tištěné verzi.

PODĚKOVÁNÍ

Rád bych poděkoval vedoucímu bakalářské práce panu doc. Ing. Petru Benešovi, Ph.D. za odborné vedení, konzultace, trpělivost a podnětné návrhy k práci.

Obsah

Úvod	23
Cíle práce	25
1 Úvod do problematiky testování materiálů, metody vlastního testování, metoda akustické emise	27
1.1 Nedestruktivní testování	27
1.2 Metody nedestruktivního testování	27
1.3 Metoda AE. Její výhody, limity	28
1.4 Postupy použití metody AE u složitějších struktur	29
1.4.1 Techniky založené na modelech	29
1.4.2 Techniky založené na strojovém učení	29
1.5 Aplikace strojového učení při testování metodou AE v komerční sféře	30
1.5.1 Software od firmy Vallen	30
1.5.2 Software od firmy Physical acoustic (MISTRAS)	34
1.6 Shrnutí současných trendů, budoucnost modelů strojového učení pro lokalizaci zdrojů AE	36
1.7 Experiment	36
2 Výsledky studentské práce	39
2.1 Programové řešení	39
Závěr	41
Literatura	43
Seznam symbolů a zkratk	45
Seznam příloh	47
A Některé příkazy balíčku thesis	49
A.1 Příkazy pro sazbu veličin a jednotek	49
A.2 Příkazy pro sazbu symbolů	49
B Druhá příloha	51
C Příklad sazby zdrojových kódů	53
C.1 Balíček listings	53
D Obsah elektronické přílohy	57

Seznam obrázků

1.1	Signál akustické emise pro vzdálenost senzoru od zdroje 3 cm [8] . . .	31
1.2	Signál akustické emise pro vzdálenost senzoru od zdroje 6 cm [8] . . .	31
1.3	Signál akustické emise pro vzdálenost senzoru od zdroje 11 cm [8] . .	32
1.4	Frekvenční analýza pro signál AE z obrázku 1.1 [8]	32
1.5	Fisherovy poměry pro všechny třídy (nahore), pro vybrané třídy (dole) [8]	33
1.6	Zobrazení "příznaku proti příznaku"(feature-feature projekce) [8] . . .	34
1.7	Příklad okna v softwaru NOESIS [9]	34
1.8	Příklad dendrogramu v softwaru NOESIS [9]	35
1.9	Příklad extrahovaného příznaku v softwaru NOESIS [9]	35
1.10	Měřicí pracoviště	37
B.1	Alenčino zrcadlo	51

Seznam tabulek

A.1	Přehled příkazů	49
-----	---------------------------	----

Seznam výpisů

C.1	Ukázka sazby zkratk	53
C.2	Příklad Schur-Cohnova testu stability v prostředí Matlab.	54
C.3	Příklad implementace první kanonické formy v jazyce C.	55

Úvod

Úvod studentské práce, např. . .

Nečíslovaná kapitola Úvod obsahuje „seznámení“ čtenáře s problematikou práce. Typicky se zde uvádí: (a) do jaké tematické oblasti práce spadá, (b) co jsou hlavní cíle celé práce a (c) jakým způsobem jich bylo dosaženo. Úvod zpravidla nepřesahuje jednu stranu. Poslední odstavec Úvodu standardně představuje základní strukturu celého dokumentu.

Tato práce se věnuje oblasti **DSP!** (**DSP!**), zejména jevům, které nastanou při nedodržení Nyquistovy podmínky pro ***symfvz!*** (***symfvz!***).¹

Šablona je nastavena na *dvoustranný tisk*. Nebuďte překvapeni, že ve vzniklém PDF jsou volné stránky. Je to proto, aby důležité stránky jako např. začátky kapitol začínaly po vytisknutí a svázání vždy na pravé straně. Pokud máte nějaký závažný důvod sázet (a zejména tisknout) jednostranně, nezapomeňte si přepnout volbu *twoside* na *oneside*!

¹Tato věta je pouze ukázkou použití příkazů pro sazbu zkratk.

Cíle práce

Konkrétní specifikace cílů, které má autor v práci vyřešit. Tato kapitola je *volitelná* – pokud váš studijní program nevyžaduje zvláštní kapitolu s cíli, cíle specifikujte v rámci Úvodu.

1 Úvod do problematiky testování materiálů, metody vlastního testování, metoda akustické emise

1.1 Nedestruktivní testování

V technické praxi jsou struktury namáhány mnoha vnějšími vlivy, čímž se mění jejich materiálové vlastnosti. Například, u laminátových konstrukcí v leteckém průmyslu může vlivem sil nárazu pevnost v tlaku klesnout až o 80%, i když se materiál jeví jako nepoškozený [1].

Pro posouzení stavu materiálu je proto nutné provádět pravidelné testování. Za účelem stanovení mezních vlastností materiálu jako pevnosti v tlaku, pevnosti v tahu, lomové houževnatosti, atd., bývá prováděno *destruktivní testování* (DT). Zahrnuje např. zkoušku tahem, tlakem, nebo ohybem. K těmto zkouškám jsou používány speciální stroje – kladiva, trhačky, ohýbačky, aj. Jak je z názvu přímo patrné, vlastní destruktivní zkoušení končí nevratným poškozením vzorku.

Pro již hotové konstrukce (např. svařované konstrukce v zámečnické výrobě, betonové pilíře v oblasti stavebnictví) nebo komponenty (hřídele, ozubená kola, kolejničky, atd.) se metody DT zpravidla nepoužívají, jelikož by takové zkoušení bylo příliš nákladné. Nabízí se proto použití metod *nedestruktivní testování* (NDT). Počátky NDT sahají do 19. století, kdy pomocí tzv. akustického poklepového testování byly detekovány praskliny na železničních kolech [2].

1.2 Metody nedestruktivního testování

Velká výhoda metod NDT spočívá v možnosti zkoušení v kterékoliv části životního cyklu produktu, u některých metod dokonce i v průběhu vykonávání vlastní činnosti výrobku. Díky tomu dostáváme přesné informace o poloze a závažnosti případného defektu ve struktuře materiálu. V současné době na trhu dominuje pět metod nedestruktivního testování – zkoušení magnetickými částicemi, radiografické zkoušení, ultrazvukové zkoušení, zkoušení vířivými proudy a zkoušení metodou akustické emise (dále AE).

Zkoušení magnetickými částicemi spočívá ve vystavení feromagnetických materiálů magnetickému poli. Díky vysoké permeabilitě feromagnetického materiálu se magnetické domény orientují ve směru působení magnetického pole, tvoří tak souvislé čáry. V případě nespojitosti materiálu dojde k tzv. úniku magnetického pole – čáry v bodě defektu nebudou spojitě. Pro snadnou viditelnost těchto nespojitostí

je použit prášek oxidu železitého, který zmíněné čáry a nespojitosti kopíruje [4]. Mezi limity spadá možnost použití jen pro feromagnetické materiály (železo, kobalt, nikl, ferity, gadolinium, aj.) [3].

Radiografické zkoušení je postup založen na snímání obrázků s využitím radioaktivního zdroje záření. Záření je pohlcováno materiálem a dochází tak k útlumu. Defekty na těchto snímcích lze rozpoznat jako místa s menším útlumem záření [4]. Limity představuje nutnost radiační ochrany a nevhodnost použití pro porézní materiály (např. beton, dřevo, sádra, keramiky, kosti aj.) [3]

Při zkoušení ultrazvukem je používáno zvukových vln. Piezoelektrický snímač generuje pulzy, které se šíří materiálem. Cestují-li tyto pulzy nepoškozenou, spojitou strukturou, nemění se jejich parametry (především tedy rychlost). Při defektu dochází ke změně rychlosti pulzů.[4].

Během zkoušení vířivými proudy je kovový materiál umístěn do fluktuujícího magnetického pole, které je vytvářeno cívkou. V kovovém materiálu jsou indukovány proudy s vířivou povahou (proto vířivé proudy). Těmito vířivými proudy je vytvořeno sekundární magnetické pole, které ovlivňuje pole cívky. S defektem ve struktuře materiálu dojde tedy ke změně i vířivých proudů, což ovlivní i primární magnetické pole cívky [4].

1.3 Metoda AE. Její výhody, limity

V případě, že je kovový materiál deformován, uvolňuje se energie ve formě tzv. elastických vln. Tyto elastické vlny jsou vlny vysoké frekvence, které cestují směrem k povrchu materiálu. Na povrchu tato data sbírají snímače AE. Souřadnice zdrojů AE jsou nejčastěji stanovovány pomocí známého triangulačního algoritmu (podle normy ČSN 14584 [5]) dle časových diferencí příchodů signálů k jednotlivým snímačům. Tyto snímače jsou na zkoušeném vzorku umístěny v husté síti.

Oproti ultrazvukovému testování je velkou výhodou zkoušení AE možnost nepřetržitého monitorování komponent – při ultrazvukovém zkoušení je potřeba externí zdroj zvuku o vysoké frekvenci. Metodou *akustická emise* (AE) se kromě toho nabízí testovat i nekovové nebo porézní materiály a najde tak uplatnění i v netechnických a medicínských oborech (např. diagnostika kostí a kloubů v ortopedii).

Limit metody AE spočívá hlavně v interpretaci dat u komplikovanějších struktur – analytické vzorce pro lokalizace zdrojů AE jsou známy jen pro tenkou, izotropní desku [6]. Navíc, instalace senzorů na všech požadovaných místech je mnohdy nesnadná. Může tomu tak být z důvodu nepřístupnosti do určitých lokalit konstrukcí (např. některé koutové sváry). Umístění snímačů dokáže mimo to nežádoucím způsobem ovlivnit dynamické vlastnosti konstrukce.

1.4 Postupy použití metody AE u složitějších struktur

Testování materiálů metodou AE můžeme formulovat dvěma základními způsoby; při **dopředné úloze** je stanovována odezva dle známých vstupů (sil nárazů). Nelze-li snadno získat hodnotu vstupu, je formulován problém zpětný – ze změřené odezvy se dopočítávají hodnoty vstupů. Tento způsob řešení nazveme **inverzním algoritmem** [1].

Ve vědeckých studiích bývají tyto inverzní algoritmy k rekonstrukci působení vnějších sil hojně využívány. Podle implementace již zmíněné inverzní algoritmy jde rozdělit na techniky založené na modelech a techniky založené na strojovém/hlubokém učení.

1.4.1 Techniky založené na modelech

Při testování materiálu je odezva (signál AE) zpracovaná předem vytvořeným modelem. Tento model dle zpracované odezvy stanovuje vstupní hodnotu a následně polohu nespojitosti materiálu. Výhoda této techniky spočívá v nízké výpočetní náročnosti. V používání limituje nutnost tvorby přesného modelu pro přepočty – jak již bylo výše uvedeno, pro stanovení vad u komplikovanějších anizotropních materiálů nejsou známy analytické vzorce, a je proto velmi obtížné tvořit modely pro testování těchto materiálů. Proto probíhá snaha uplatnit při lokalizaci zdrojů AE algoritmy strojového učení.

1.4.2 Techniky založené na strojovém učení

V posledních letech se algoritmy strojového učení stávají velmi vhodnými při rekonstrukci dat AE – dají se aplikovat i tehdy, když základní mechanismy pro nás nejsou zcela známy a nedovedeme tak správně sestavit model. Nicméně, pro správné uplatnění technik strojového učení představuje omezení nutnost velkého objemu tréninkových dat.

Neexistuje žádná záruka, že tréninková data získaná pro jednu strukturu přinesou smysluplné výsledky i u struktur odlišných. V posledních letech jsou prozkoumávány proto metody tzv. hlubokého učení (nebo také deep learningu), které umožňují použití dat i v surové podobě. S použitím metod hlubokého učení lze tak interpretovat dokonce i vícerozměrné signály AE.

Důležitým algoritmem, na kterém stojí velká většina modelů hlubokého učení, je **umělá neuronová síť**. Stejně jako ostatní metody hlubokého učení potřebují ke své funkci velký objem tréninkových dat. Studie (například [7]) se v současné době snaží pomocí neuronových sítí identifikovat vnější síly, které způsobují deformační

změny na kompozitních panelech. Výhodou neuronových sítí je nepotřeba předchozích znalostí poloh zdrojů deformace. Ve výše uvedené studii jsou aplikovány dvě neuronové sítě – jedna pro deformace o vyšších amplitudách, druhá pro deformace o amplitudách menších.

Navzdory obrovskému potenciálu nejsou umělé neuronové sítě v nelineárních strukturách zcela široce využívány. Způsobují to fakta, že nejčastěji používaná architektura umělých neuronových sítí pracuje s dvourozměrnými vstupy. Prvním parametrem je rozsah datového setu, který je k dispozici k trénování sítě. Druhým je samotný příznak čili měřená data, která neuronové síti přidělíme k učení. Tyto parametry nezahrnují čas, jenž je k rekonstrukci zdroje deformace nezbytný.

Navíc, pro výběr kvalitních příznaků do učící sady je nezbytná lidská expertíza. Tvorba učící sady je poměrně náročná a nelze ji nijak efektivně automatizovat. Při rekonstrukci zdroje deformace mimo jiné představuje problém již výše popsany u technik založených na modelech – pro získání kvalitních dat je nutné rozmístit senzory v husté síti, a to zhoršuje dynamické parametry konstrukce.

1.5 Aplikace strojového učení při testování metodou AE v komerční sféře

AE se někdy označuje jako pasivní ultrazvuk, protože ultrazvukové snímače oproti snímačům AE potřebují pro správnou lokalizaci externí zdroj zvuku o vyšší frekvenci než 20 kHz. Někteří výrobci ultrazvukových snímačů a defektoskopů, jako například Olympus, se proto úzce specializují i na diagnostiku metodou AE.

Velkým výrobcem, který je kromě diagnostiky materiálů dříve zmíněnými metodami (ultrazvukové testování, testování vířivými proudy, a další) zaměřen i na diagnostiku metodou AE, je americká MISTRAS group (patří k nim Physical Acoustic). Konkuruje jim menší německá firma, která vyrábí rovněž kvalitní a uznávané systémy, snímače a předzesilovače pro testování metodou AE. je Vallen Systeme. Tito dva nejvýznamnější výrobci kromě toho ladí a vyvíjejí software k automatické a efektivnější klasifikaci dat pomocí strojového učení.


1.5.1 Software od firmy Vallen

Program od firmy Vallen se jmenuje VisualClass. Jak je z názvu přímo patrné, jedná se primárně o nástroj pro automatickou klasifikaci dat – každé vlně přidělí určité číslo třídy. V každé z těchto přidělených tříd klasifikuje podobnost se vzorovými daty. Funkcí, která představuje míru podobnosti mezi vlastní změřenou vlnou a vzorem, je **poměr vzdáleností**.


Čím nižší je poměr vzdáleností, tím lépe odpovídá aktuální průběh přidělené třídě. Výsledky těchto klasifikátorů mohou být pro každý dílčí detekovaný zásah v programu VisualAE (program od společnosti Vallen pro analýzu dat AE. Zpracovává jak dvojrozměrná, tak trojrozměrná data, počítá hodnoty nejistot měření, atd.) spojeny s odpovídajícími parametry. Klasifikované výsledky lze tak rovnou i statisticky zpracovat.

Výše zmíněný klasifikátor (čili kritérium, kterým jsou vlnové průběhy přidělovány do tříd) lze chápat jako výsledek trénování modelu nebo také procesu učení modelu. V rámci procesu učení je brán určitý počet datových (učících) sad. Byla-li data vybrána uživatelem, hovoří se o **řízeném učení** (supervised learning). Pokud byly tyto sady vybrány automaticky nějakým výkonným algoritmem tzv. clusteringu (shromažďování dat, "shlukování"), jde potom o učení **neřízené** (unsupervised learning).


Průběhy uvedené na obrázcích 1.1, 1.2 a 1.3 byly změřeny shodným senzorem, zpracování proběhlo softwarem od VisualClass. Vzdálenost zdroje AE od snímače jsou 3, 6 a 11 cm. Pro každou z níže uvedených pozic bylo generováno deset pulzů.



Obr. 1.1: Signál akustické emise pro vzdálenost senzoru od zdroje 3 cm [8]




Obr. 1.2: Signál akustické emise pro vzdálenost senzoru od zdroje 6 cm [8]



Obr. 1.3: Signál akustické emise pro vzdálenost senzoru od zdroje 11 cm [8]

Pro takto změřené signály AE potom VisualClass dokáže zobrazovat spektra krátkodobé frekvenční analýzy (zobrazení spektrogramu). Příklad frekvenční analýzy pro průběh uvedený na obrázku 1.1 je uveden na obrázku 1.4. Jak lze na ob-




Obr. 1.4: Frekvenční analýza pro signál AE z obrázku 1.1 [8]

rázku 1.4 vidět, je signál rozdělen na malé časové segmenty. Každý z těchto časových segmentů je zobrazen pomocí Hammingova okna, abychom se vyhnuli strmým hranám oken. Tyto hrany totiž zkreslují skutečné průběhy. Následně se pro každý v horní části obrázku 1.4 vyznačený časový segment pomocí algoritmu FFT stanoví vlastní spektrum, jak lze vidět ve spodní části obrázku 1.4.


Počet časových segmentů, počet vzorků na segment nebo rozsah harmonických, jsou parametry nastavitelné uživatelem společně se stovkami dalších funkcí pro signálové operace. Jak dobře změřený signál a jeho vlastnosti odpovídají vzoru, udávají tzv. Fischerovy poměry. Sledované vlastnosti lze vybrat přímo, nebo automaticky.

Na obrázku 1.5 vidíme příklad těchto poměrů, kde červené tečky představují klasifikátor, se kterým se právě pracuje.



Obr. 1.5: Fisherovy poměry pro všechny třídy (nahore), pro vybrané třídy (dole) [8]


Působivou funkcí softwaru VisualClass pro srovnávání několika naměřených průběhů navzájem mezi sebou je schopnost zobrazení příznaku proti příznaku (feature-feature projekce). Jde o zobrazení závislosti jednoho příznaku na druhém příznaku – jedné extrahované veličiny (příznaku) na druhé extrahované veličině. Každý změřený průběh AE patřící k jedné třídě značí barevný symbol. Díky tomuto zobrazení lze snadno ověřit rozdíly jak mezi signály stejné třídy, tak mezi několika třídami. Zobrazení feature-feature demonstruje obrázek 1.6



Obr. 1.6: Zobrazení "příznaku proti příznaku" (feature-feature projekce) [8]

1.5.2 Software od firmy Physical acoustic (MISTRAS)


Software NOESIS od společnosti Physical acoustic umožňuje rozpoznávání vzorů (pattern recognition) a práci s neuronovými sítěmi podobně, jako VisualClass. Jedná se tak podobně o software sloužící k automatické klasifikaci dat. Provádí korelaci jednotlivých příznaků - klasifikaci dat pro průzkum a datovou analýzu většího množství průběhů zároveň. Data pro třídu (nebo také cluster) mohou být vybrána uživatelem. NOESIS umí základní signálové manipulace a výpočet jednoduchých operací, jako jsou FFT nebo RMS, podobně jako VisualClass. Typický příklad rozložení v jednom okně lze vidět na obrázku 1.7.




Obr. 1.7: Příklad okna v softwaru NOESIS [9]

Kromě pouhého zobrazování dat umí NOESIS vést i pokročilejší statistiky. Podobně jako VisualClass počítá příznaky (features) z jednotlivých průběhů. Dovede

počítat až 50 příznaků, např. amplitudu (dBae), dobu náběhu (μs), energii signálu (aJ), a další uvedené v [9]. Z těchto příznaků (příklad extrahovaného příznaku uveden na 1.9) umí stanovit diskriminant, nebo také určit diskriminant celé třídy. K vizualizaci vztahů mezi jednotlivými příznaky a propojení podobných příznaků slouží dendrogram ukázaný na obrázku 1.8.



Obr. 1.8: Příklad dendrogramu v softwaru NOESIS [9]



Obr. 1.9: Příklad extrahovaného příznaku v softwaru NOESIS [9]

Jak je z obrázků 1.8 a 1.9 patrné, NOESIS nabízí celou řadu algoritmů pro automatickou klasifikaci dat. Dovede pomocí výkonného algoritmu (tzv. clusteringu, jak bylo uvedeno již v sekci 1.5.2) vybírat data, jedná se o neřízené učení. Uživatel

je v tomto případě nechán nastavit omezený počet parametrů a získat podle těchto parametrů automatickou klasifikaci. Plně automatizované funkce pro klasifikaci dat známé jako řízené učení oproti tomu požadují po uživateli, aby nahrál učící sadu. Po zadání učící sady může být model vytrénován a následně automaticky klasifikovat předem neznámá data [9].

1.6 Shrnutí současných trendů, budoucnost modelů strojového učení pro lokalizaci zdrojů AE

Z kapitoly 1.9 plyne, že se v současné době algoritmy strojového učení komerčně využívají spíše pro automatickou klasifikaci naměřených dat AE, než pro přímé lokalizování zdrojů AE. Techniky strojového učení ale přesto do budoucna reprezentují alternativní přístup k tradičním metodám lokalizace zdrojů AE. Navzdory potřebě velkého množství dat pro trénink algoritmů mohou techniky strojového učení testování materiálů metodou AE optimalizovat. Vlastní výkon modelu založeného na strojovém učení závisí především na datovém setu, který byl použit pro učení [10]. Jak již bylo dříve uvedeno, použití strojového učení pro lokalizaci zdrojů AE komplikuje nutnost lidské expertízy pro naměření a výběr nejlepších dat do datasetu. Nelze tak proces řízeného učení efektivně automatizovat.

Velkou nevýhodou modelů strojového učení je také náchylnost k poruše. V případě, že sledujeme data, která jsou špatná (např. chybí některá data z důvodu poruchy akvizičního zařízení, přesuneme se do prostředí se šumem, atd.), začne být diagnostika nespolehlivá. Předmětem výzkumů v této oblasti je tak stanovení detailnějších charakteristik signálů AE za účelem sestavení modelů se schopností rozlišovat jednotlivé vady nebo poruchy. Pro vyhodnocování a identifikaci anomálních dat mohou být velice užitečné výše zmíněné výkonné algoritmy tzv. clusteringu neboli shlukování [10]. Probíhá proto také snaha o vývoj algoritmů clusteringu (tj. algoritmů pro neřízené učení) s vyšším výpočetním výkonem.

1.7 Experiment

První experiment byl proveden dne 31. října 2025 na duralové desce s rozměry 430 x 513 x 2,75 mm. Byl prováděn tzv. pentest - od snímače AE značky Olympus byla lámána tuha o tloušťce 0,3 mm a tvrdosti 2H (dle normy ČSN 14584[5]) ve vzdálenostech 5, 10, 15, 20, 25, 30, 35 a 40 cm. Podle normy ČSN 14584[5] byl snímač zatížen silou o velikosti 10 N – bylo použito závaží o hmotnosti 1000,03 g. Data ze snímače AE zpracovávala dvoukanálová měřicí ústředna Dakel. Vlastní naměřené průběhy byly zobrazovány na notebooku, kde byl nainstalován program

ZEDO [11] pro komunikaci s ústřednou. Pro každou zmíněnou vzdálenost od snímače



Obr. 1.10: Měřicí pracoviště

bylo provedeno několik tzv. pentestů. Po dokončení každé sady dat (tj. dat určených pro jednu ze vzdáleností) byl proveden export. Program ZEDO každý průběh exportoval tak, že vygeneroval binární soubor se surovými hodnotami AD převodu (*.bin), textový soubor s informacemi o získaných vzorcích a gnuplot soubor (*.plt) pro snadné zobrazení grafů mezi různými operačními systémy. Vypočtené hodnoty **RMS**, **ASL**, a **výkon signálu** byly vloženy do textového souboru, jehož názvu bylo součástí označení "ae-parameters". Pro tyto parametry platí dle dokumentace [11] následující vztahy:

$$U_{RMS} = \sqrt{\frac{1}{N} \cdot \sum_{i=1}^N u_i^2} \quad (1.1)$$

kde:

U_{RMS} ... napětí efektivní hodnoty signálu (z angl. root mean square) [V]

N ... počet diskretních vzorků napětí (parametr každého z průběhů) [-]

u_i ... hodnota napětí pro daný vzorek i (spočtená z periferní hodnoty dle vztahu – dodat VZTAH) [V]

$$U_{ASL} = \frac{1}{N} \cdot \sum_{i=1}^N |u_i| \quad (1.2)$$

kde:

U_{ASL} ... napětí střední hodnoty signálu (z angl. average signal level) [V]

$$P = \frac{1}{N} \cdot \sum_{i=1}^N u_i^2 \quad (1.3)$$

Snahou bylo vybrat jeden nejlepší průběh z každé sady, pro který by

2 Výsledky studentské práce

Praktická část a výsledky studentské práce vhodně rozdělené do částí.

2.1 Programové řešení

Závěr

Shrnutí studentské práce.

Literatura

- [1] KALHORI, H., TASHAKORI, C., HALKON, B. et al.: Advances in impact force identification: A comprehensive review of techniques and mathematical innovations. Results in Engineering. 2025, č. 26 [online]. Dostupné z: <https://www.sciencedirect.com/science/article/pii/S259012302501638X>
- [2] HELAL, J., SOFI, M. a MENDIS, P. Non-Destructive Testing of Concrete: A Review of Methods. Electronic Journal of Structural Engineering. 2015, č. 14 [online]. Dostupné z: <https://ejsei.com/EJSE/article/view/193>.
- [3] DWIVEDIA, S. K., VISHWAKARMAB, M., SONIC, A.: Advances and Researches on Non Destructive Testing: A Review[online]. 2017. Dostupné z: <https://www.sciencedirect.com/>
- [4] MRIDUL G., MUHSIN, A. K., RAVI B. et al. Advances in applications of Non-Destructive Testing (NDT): A review. Advances in Materials and Processing Technologies [online]. 2021. ISSN 2374 0698. Dostupné z: <https://www.tandfonline.com/journals/tmpt20?src=pdf>
- [5] ČSN EN 14584 (01 5089) – Nedestruktivní zkoušení – Kvalifikace a certifikace personálu nedestruktivního zkoušení – Doplnující požadavky pro certifikaci podle EN ISO 9712 pro pracovníky provádějící akustickou emisní zkoušku kovových tlakových zařízení během provozu. Praha: Úřad pro technickou normalizaci, metrologii a státní zkušebnictví (ÚNMZ), 2013.
- [6] CHLADA, M., BLAHÁČEK, M., PŘEVOROVSKÝ Z. Aplikace časových profilů při lokalizaci zdrojů AE pomocí neuronových sítí [online]. Dostupné z: <https://www.ndt.net/?id=8781>
- [7] GHAJARI, M., SHARIF-KHODAEI, ALIABADI, M. H. Identification of impact force for smart composite stiffened panels [online]. Dostupné z: <https://iopscience.iop.org/article/10.1088/0964-1726/22/8/085014>
- [8] VALLEN-Systeme GmbH. Vallen VisualClass™ – The AE tool for recognizing waveform similarities. Icking (Munich): Vallen-Systeme GmbH, 2002. 4 s. Dostupné z: <http://www.vallen.de>
- [9] KATTIS, S. Noesis – Advanced Data Analysis, Pattern Recognition & Neural Networks Software For Acoustic Emission Applications [online]. Dostupné z: <https://www.ndt.net/article/dgzfp-ae-2017/papers/12.pdf>

- [10] CIABURRO, G. IANNACE, G. Machine-Learning-Based Methods for Acoustic Emission Testing: A Review [online].
Dostupné z: <https://doi.org/10.3390/app122010476>
- [11] DAKEL. ZEDO installation guide and user manual. ZD Rpety: DAKEL, [bez data].

Seznam symbolů a zkratek

DT	destruktivní testování
NDT	nedestruktivní testování
AE	akustická emise

Seznam příloh

A	Některé příkazy balíčku <code>thesis</code>	49
A.1	Příkazy pro sazbu veličin a jednotek	49
A.2	Příkazy pro sazbu symbolů	49
B	Druhá příloha	51
C	Příklad sazby zdrojových kódů	53
C.1	Balíček <code>listings</code>	53
D	Obsah elektronické přílohy	57

A Některé příkazy balíčku thesis

A.1 Příkazy pro sazbu veličin a jednotek

Tab. A.1: Přehled příkazů pro matematické prostředí

Příkaz	Příklad	Zdroj příkladu	Význam
<code>\textind{...}</code>	$\beta_{\max}$	<code>\$\beta_{\textind{max}}\$</code>	textový index
<code>\const{...}</code>	U_{in}	<code>\$\const{U}_{\textind{in}}\$</code>	konstantní veličina
<code>\var{...}</code>	u_{in}	<code>\$\var{u}_{\textind{in}}\$</code>	proměnná veličina
<code>\complex{...}</code>	$\mathbf{u}_{\text{in}}$	<code>\$\complex{u}_{\textind{in}}\$</code>	komplexní veličina
<code>\vect{...}</code>	$\mathbf{y}$	<code>\$\vect{y}\$</code>	vektor
<code>\mat{...}</code>	$\mathbf{Z}$	<code>\$\mat{Z}\$</code>	matice
<code>\unit{...}</code>	kV	<code>\$\unit{kV}\$</code> či <code>\unit{kV}</code>	jednotka


A.2 Příkazy pro sazbu symbolů

- `\E`, `\eul` – sazba Eulerova čísla: e,
- `\J`, `\jmag`, `\I`, `\imag` – sazba imaginární jednotky: j, i,
- `\dif` – sazba diferenciálu: d,
- `\sinc` – sazba funkce: sinc,
- `\mikro` – sazba symbolu mikro stojatým písmem¹: μ,
- `\uppi` – sazba symbolu π (stojaté řecké pí, na rozdíl od `\pi`, což sází π).

Všechny symboly jsou určeny pro matematický mód, vyjma `\mikro`, jenž je použitelný rovněž v textovém módu.

¹znak pochází z balíčku `textcomp`

B Druhá příloha



Obr. B.1: Zlepšené Wilsonovo proudové zrcadlo.

Pro sazbu vektorových obrázků přímo v $\text{\LaTeX}$ je možné doporučit balíček `TikZ`. Příklady sazby je možné najít na `TExample`. Pro vyzkoušení je možné použít programy `QTikz` nebo `TikzEdt`.

C Příklad sazby zdrojových kódů

C.1 Balíček listings

Pro vysázení zdrojových souborů je možné použít balíček `listings`. Balíček zavádí nové prostředí `lstlisting` pro sazbu zdrojových kódů, jako například:

```
\section{Balíček listings}
Pro vysázení zdrojových souborů je možné použít
  balíček \href{https://www.ctan.org/pkg/listings}%
  {\texttt{listings}}.
Balíček zavádí nové prostředí \texttt{lstlisting} pro
  sazbu zdrojových kódů.
```

Podporuje množství programovacích jazyků. Kód k vysázení může být načítán přímo ze zdrojových souborů. Umožňuje vkládat čísla řádků nebo vypisovat jen vybrané úseky kódu. Např.:

Zkratky jsou sázeny v prostředí `acronym`:

```
6 \begin{acronym}[KolikMista]
```

Šířka textu volitelného parametru `KolikMista` udává šířku prvního sloupce se zkratkami. Proto by měla být zadávána nejdelší zkratka nebo symbol. Příklad definice zkratky `symfvz!` je na výpisu C.1.

Výpis C.1: Ukázka sazby zkratek

21	<code>\acro{NDT}</code>	<code>% název</code>
22	<code>% [\ensuremath{f_textind{vz}}]</code>	<code>% symbol</code>
23	<code>{nedestruktivní testování}</code>	<code>% popis</code>

Ukončení seznamu je provedeno ukončením prostředí:

```
26 {akustická emise}
```

Poznámka k výpisům s použitím volby jazyka czech nebo slovak:

Pokud Váš zdrojový kód obsahuje znak spojovníku `-`, pak překlad může skončit chybou. Ta je způsobená tím, že znak `-` je v českém nebo slovenském nastavení balíčku `babel` tzv. aktivním znakem. Přepněte znak `-` na neaktivní příkazem `\shorthandoff{-}` těsně před výpisem a hned za ním jej vraťte na aktivní příkazem `\shorthandon{-}`. Podobně jako to je ukázáno ve zdrojovém kódu šablony.

Na výpisu C.2 naleznete příklad kódu pro Matlab, na výpisu C.3 zase pro jazyk C.

Výpis C.2: Příklad Schur-Cohnova testu stability v prostředí Matlab.

```
1 %% Příklad testování stability filtru
2
3 % koeficienty polynomu ve jmenovateli
4 a = [ 5, 11.2, 5.44, -0.384, -2.3552, -1.2288];
5 disp('Polynom:'); disp(poly2str( a, 'z'))
6
7 disp('Kontrola pomocí kořenu polynomu:');
8 zx = roots( a);
9 if( all( abs( zx) < 1))
10     disp('System je stabilní')
11 else
12     disp('System je nestabilní nebo na mezí stability');
13 end
14
15 disp(' '); disp('Kontrola pomocí Schur-Cohn:');
16 ma = zeros( length(a)-1,length(a));
17 ma(1,:) = a/a(1);
18 for( k = 1:length(a)-2)
19     aa = ma(k,1:end-k+1);
20     bb = fliplr( aa);
21     ma(k+1,1:end-k+1) = (aa-aa(end)*bb)/(1-aa(end)^2);
22 end
23
24 if( all( abs( diag( ma.'))))
25     disp('System je stabilní')
26 else
27     disp('System je nestabilní nebo na mezí stability');
28 end
```

Výpis C.3: Příklad implementace první kanonické formy v jazyce C.

<i>// první kanonická forma</i>	1
short fxdf2t(short coef[][5], short sample)	2
{	3
static int v1[SECTIONS] = {0,0},v2[SECTIONS] = {0,0};	4
int x, y, accu;	5
short k;	6
	7
x = sample;	8
for (k = 0; k < SECTIONS; k++){	9
accu = v1[k] >> 1;	10
y = _sadd(accu, _smpy(coef[k][0], x));	11
y = _sshl(y, 1) >> 16;	12
	13
accu = v2[k] >> 1;	14
accu = _sadd(accu, _smpy(coef[k][1], x));	15
accu = _sadd(accu, _smpy(coef[k][2], y));	16
v1[k] = _sshl(accu, 1);	17
	18
accu = _smpy(coef[k][3], x);	19
accu = _sadd(accu, _smpy(coef[k][4], y));	20
v2[k] = _sshl(accu, 1);	21
	22
x = y;	23
}	24
return (y);	25
}	26

D Obsah elektronické přílohy

Elektronická příloha je často nedílnou součástí semestrální nebo závěrečné práce. Vkládá se do informačního systému VUT v Brně ve vhodném formátu (ZIP, PDF ...).

Nezapomeňte uvést, co čtenář v této příloze najde. Je vhodné okomentovat obsah každého adresáře, specifikovat, který soubor obsahuje důležitá nastavení, který soubor je určen ke spuštění, uvést nastavení kompilátoru atd. Také je dobře napsat, v jaké verzi software byl kód testován (např. Matlab 2018b). Pokud bylo cílem práce vytvořit hardwarové zařízení, musí elektronická příloha obsahovat veškeré podklady pro výrobu (např. soubory s návrhem DPS v Eagle).

Pokud je souborů hodně a jsou organizovány ve více složkách, je možné pro výpis adresářové struktury použít balíček `dirtree`.

```
/.....kořenový adresář přiloženého archivu
├── logo ..... loga školy a fakulty
│   ├── BUT_abbreviation_color_PANTONE_EN.pdf
│   ├── BUT_color_PANTONE_EN.pdf
│   ├── FEEC_abbreviation_color_PANTONE_EN.pdf
│   ├── FEKT_zkratka_barevne_PANTONE_CZ.pdf
│   ├── UTKO_color_PANTONE_CZ.pdf
│   ├── UTKO_color_PANTONE_EN.pdf
│   ├── VUT_barevne_PANTONE_CZ.pdf
│   ├── VUT_symbol_barevne_PANTONE_CZ.pdf
│   └── VUT_zkratka_barevne_PANTONE_CZ.pdf
├── obrazky ..... ostatní obrázky
│   ├── soucastky.png
│   ├── spoje.png
│   ├── ZlepseneWilsonovoZrcadloNPN.png
│   └── ZlepseneWilsonovoZrcadloPNP.png
├── pdf ..... pdf stránky generované informačním systémem
│   ├── student-desky.pdf
│   ├── student-titulka.pdf
│   └── student-zadani.pdf
├── text ..... zdrojové textové soubory
│   ├── literatura.tex
│   ├── prilohy.tex
│   ├── reseni.tex
│   ├── uvod.tex
│   ├── vysledky.tex
│   ├── zaver.tex
│   └── zkratky.tex
├── sablona-obhaj.tex ..... hlavní soubor pro sazbu prezentace k obhajobě
├── sablona-prace.tex ..... hlavní soubor pro sazbu kvalifikační práce
└── thesis.sty ..... balíček pro sazbu kvalifikačních prací
```